Data warehouse
Livraison de nourriture

Rapport de construction et contenu de l'entrepôt de données

11 octobre 2026 · base SQLite entrepot_livraison.db

56 992	45 593	388	22 · 1 320
livraisons chargées (train + test)	livraisons avec temps de livraison	réponses à l'enquête clients (Bangalore)	villes · livreurs

Période couverte par les commandes : du 11/02/2022 au 06/04/2022.

Contenu du rapport

1 Sources et données chargées
2 Architecture de l'entrepôt (schéma en constellation)
3 Dictionnaire des données
4 Contenu des dimensions
5 Aperçu des tables de faits
6 Premières analyses
7 Qualité des données : anomalies corrigées et contrôles
8 Limites à connaître
A Reproduire la construction, exemples de requêtes

1. Sources et données chargées

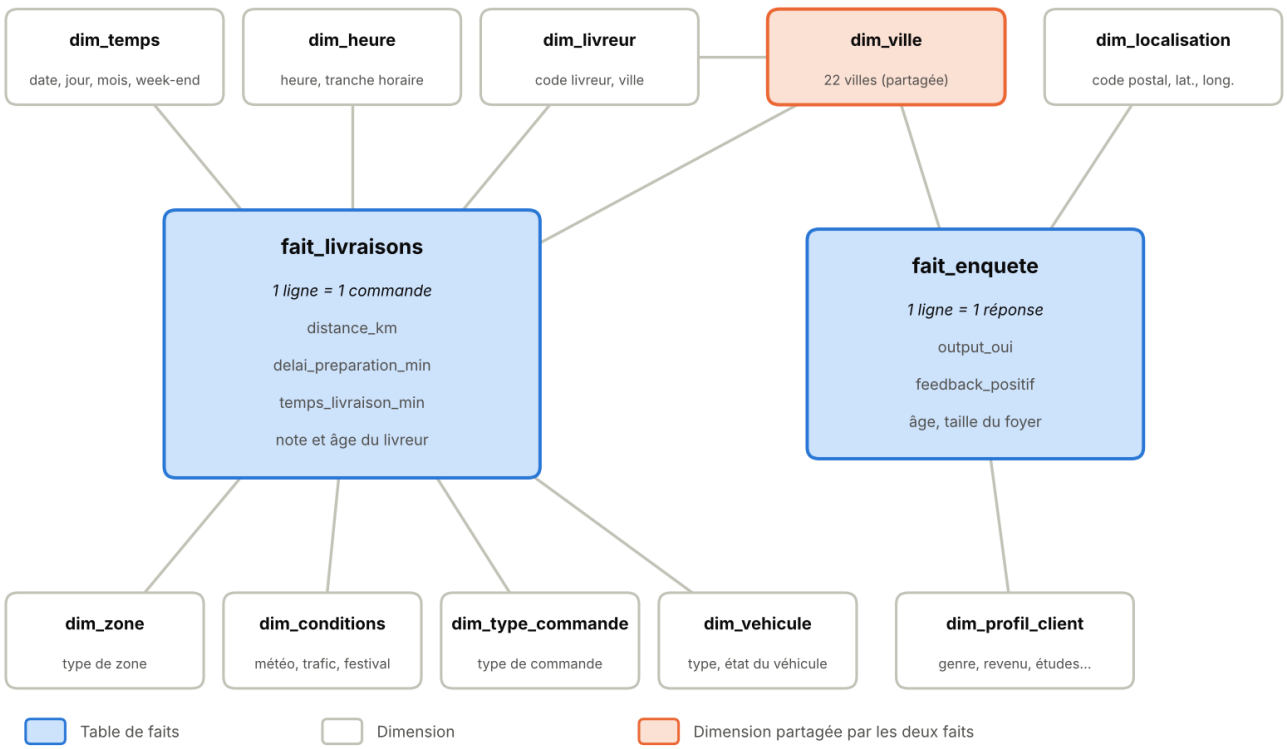
L'entrepôt réunit deux jeux de données de livraison de nourriture en Inde : les commandes d'un service de livraison (fichiers train et test) et une petite enquête auprès de clients de Bangalore. Chaque fichier a d'abord été copié tel quel dans des tables de *staging* (stg_train, stg_test, stg_enquete), puis nettoyé et chargé dans les dimensions et les faits.

Fichier source	Contenu	Lignes	Destination
train.csv	Commandes, avec le temps de livraison	45 593	fait_livraisons (jeu_donnees = train)
test.csv	Commandes, sans temps de livraison	11 399	fait_livraisons (jeu_donnees = test)
online food delivery dataset.csv	Enquête auprès de clients de Bangalore	388	fait_enquete
Sample_Submission.csv	Modèle de soumission : temps d'exemple pour les commandes du test	11 399	**Non chargé** : valeurs d'exemple, pas des mesures
train-selected-columns.csv (×2)	Fichiers reçus vides (en-têtes seulement)	0	**Non utilisés**

Les valeurs textuelles (météo, type de véhicule, profils de l'enquête…) restent dans la langue de la source, l'anglais. Les libellés de ce rapport sont en français.

2. Architecture de l'entrepôt

Le schéma est une **constellation de faits** : deux tables de faits qui partagent une dimension commune, `dim_ville`. Chaque fait est entouré de ses dimensions, comme dans un schéma en étoile.



Chaque trait relie une table de faits à une dimension par une clé étrangère. La seule liaison entre l'enquête et les livraisons passe par la ville, car l'enquête ne contient aucun identifiant de client.

Règles de conception

- **Grain** : une ligne de `fait_livraisons` = une commande ; une ligne de `fait_enquete` = une réponse à l'enquête.
- **Clés de substitution** : chaque dimension a sa propre clé entière. La clé **−1** désigne une valeur inconnue (heure ou type de zone manquants).
- **Mesures** : temps de livraison, distance (calculée à partir des coordonnées) et délai de préparation (heure de ramassage moins heure de commande).

- **Âge et note du livreur** sont stockés dans le fait et non dans `dim_livreur` : pour un même code livreur, ils changent d'une commande à l'autre dans la source.
- **Traçabilité** : les tables de staging conservent les données brutes ; `journal_anomalies` et `controle_qualite` documentent le nettoyage dans la base elle-même.

3. Dictionnaire des données

Table de faits fait_livraisons

Colonne	Type	Description
`id_livraison`	INTEGER	Clé primaire de la ligne (1 à 56 992).
`id_commande`	TEXT	Identifiant de commande d'origine (ex. 0x4607), unique.
`jeu_donnees`	TEXT	« train » (temps de livraison connu) ou « test » (temps inconnu).
`id_temps`	INTEGER	→ dim_temps : date de la commande (AAAAMMJJ).
`id_heure_commande`	INTEGER	→ dim_heure : heure de la commande (−1 si inconnue).
`id_livreur`	INTEGER	→ dim_livreur : livreur.
`id_ville`	INTEGER	→ dim_ville : ville (déduite du code livreur).
`id_zone`	INTEGER	→ dim_zone : type de zone (Metropolitan, Urban, Semi-Urban).
`id_conditions`	INTEGER	→ dim_conditions : météo, trafic routier, jour de festival.
`id_type_commande`	INTEGER	→ dim_type_commande : buffet, boissons, repas, snack.
`id_vehicule`	INTEGER	→ dim_vehicule : type et état du véhicule.
`heure_commande`	TEXT	Heure de commande au format HH:MM:SS (vide si inconnue).
`heure_ramassage`	TEXT	Heure de ramassage de la commande au restaurant.
`age_livreur`	INTEGER	Âge du livreur (vide si absent ou inférieur à 18 ans).
`note_livreur`	REAL	Note du livreur, de 1 à 5 (vide si absente ou supérieure à 5).
`livraisons_simultanees`	INTEGER	Nombre de livraisons en parallèle (colonne multiple_deliveries, 0 à 3).
`coordonnees_valides`	INTEGER	1 si les coordonnées sont exploitables, 0 sinon.
`lat_restaurant, lon_restaurant`	REAL	Position du restaurant, en degrés décimaux (vide si non valide).
`lat_livraison, lon_livraison`	REAL	Position du lieu de livraison, en degrés décimaux (vide si non valide).
`distance_km`	REAL	Mesure calculée : distance à vol d'oiseau restaurant → client (haversine).
`delai_preparation_min`	INTEGER	Mesure calculée : heure de ramassage − heure de commande, en minutes.
`temps_livraison_min`	INTEGER	Mesure principale : temps de livraison en minutes (vide pour le jeu test).

Table de faits fait_enquete

Colonne	Type	Description
`id_reponse`	INTEGER	Clé primaire de la réponse (1 à 388).
`id_profil`	INTEGER	→ dim_profil_client : genre, statut, occupation, études, revenu, type de client.
`id_localisation`	INTEGER	→ dim_localisation : code postal du répondant.
`id_ville`	INTEGER	→ dim_ville : toujours Bangalore (lien avec les livraisons).
`age`	INTEGER	Âge du répondant (18 à 33 ans).
`taille_foyer`	INTEGER	Nombre de personnes dans le foyer (1 à 6).
`output_oui`	INTEGER	1 si la colonne source « Output » vaut Yes (sens non documenté par la source).
`feedback_positif`	INTEGER	1 si l'avis est positif, 0 s'il est négatif.

Dimensions

Table	Colonnes	Rôle	Lignes
dim_temps	id_temps, date_complete, annee, mois, nom_mois, jour, jour_semaine, nom_jour, semaine_iso, est_weekend	Calendrier continu, un jour par ligne.	55
dim_heure	id_heure, libelle, tranche	Heures 0 à 23, regroupées en 5 tranches, plus « Inconnue » (−1).	25
dim_ville	id_ville, code_ville, nom_ville	Villes ; nom déduit du code livreur. Partagée par les deux faits.	22
dim_zone	id_zone, type_zone	Type de zone : Metropolitan, Urban, Semi-Urban, Inconnu.	4
dim_livreur	id_livreur, code_livreur, id_ville	Un livreur par code, rattaché à sa ville.	1 320
dim_conditions	id_conditions, meteo, trafic, festival	Combinaisons météo × trafic × festival observées.	72
dim_type_commande	id_type_commande, type_commande	Buffet, Drinks, Meal, Snack.	4
dim_vehicule	id_vehicule, type_vehicule, etat_vehicule	Combinaisons type × état du véhicule.	10
dim_profil_client	id_profil, genre, statut_marital, occupation, niveau_etudes, tranche_revenu, ordre_revenu, type_client	Profils distincts des répondants à l'enquête.	118
dim_localisation	id_localisation, code_postal, latitude, longitude	Codes postaux de l'enquête (Bangalore).	77

4. Contenu des dimensions

Valeurs des attributs et nombre de commandes concernées (train et test confondus, 56 992 commandes).

Attribut	Valeurs (nombre de commandes)
Type de zone	Metropolitan : **42 590** · Urban : **12 669** · Inconnu : **1 524** · Semi-Urban : **209**
Type de commande	Snack : **14 348** · Repas : **14 252** · Boissons : **14 242** · Buffet : **14 150**
Type de véhicule	motorcycle : **33 044** · scooter : **19 093** · electric_scooter : **4 764** · bicycle : **91**
Météo	Brouillard : **9 422** · Orageux : **9 397** · Nuageux : **9 397** · Tempête de sable : **9 373** · Venteux : **9 370** · Ensoleillé : **9 259** · Inconnu : **774**
Trafic routier	Faible : **19 358** · Embouteillage : **17 646** · Moyen : **13 698** · Élevé : **5 535** · Inconnu : **755**
Jour de festival	No : **55 600** · Yes : **1 099** · Inconnu : **293**
Tranche horaire	Soir (19h-23h) : **28 639** · Après-midi (15h-18h) : **12 941** · Matin (6h-10h) : **7 147** · Midi (11h-14h) : **5 542** · Inconnue : **2 175** · Nuit (0h-5h) : **548**
Livraisons simultanées	1 : **35 224** · 0 : **17 586** · 2 : **2 498** · Inconnu : **1 231** · 3 : **453**

Météo et trafic : Sunny = ensoleillé, Cloudy = nuageux, Fog = brouillard, Stormy = orageux, Windy = venteux, Sandstorms = tempête de sable ; Low = faible, Medium = moyen, High = élevé, Jam = embouteillage. « Inconnu » = valeur absente de la source.

dim_ville : villes, livreurs et commandes

Id	Code	Ville (déduite du code)	Livreurs	Commandes	Temps moyen (min, train)
12	JAP	Jaipur	60	4 320	26,7
4	BANG	Bangalore	60	3 960	26,1
6	CHEN	Chennai	60	3 960	26,4
7	COIMB	Coimbatore	60	3 960	26,3
10	HYD	Hyderabad	60	3 960	26,4
11	INDO	Indore	60	3 960	26,1
17	MUM	Mumbai	60	3 960	26,0
18	MYS	Mysore	60	3 960	26,0
19	PUNE	Pune	60	3 960	26,3
20	RANCHI	Ranchi	60	3 960	26,2
21	SUR	Surat	60	3 960	26,1
22	VAD	Vadodara	60	3 960	26,3
13	KNP	Kanpur	60	952	26,3
16	LUDH	Ludhiana	60	952	26,3

Id	Code	Ville (déduite du code)	Livreurs	Commandes	Temps moyen (min, train)
2	ALH	Allahabad	60	940	27,0
1	AGR	Agra	60	936	26,6
8	DEH	Dehradun	60	932	26,7
3	AURG	Aurangabad	60	880	26,6
5	BHP	Bhopal	60	880	26,8
9	GOA	Goa	60	880	26,2
14	KOC	Kochi	60	880	26,3
15	KOL	Kolkata	60	880	26,4

12 villes ont entre 3 132 et 3 443 commandes du jeu train, les 10 autres entre 691 et 763. Chaque ville compte exactement 60 livreurs. Le temps moyen va de 26,0 à 27,0 min d'une ville à l'autre.

dim_vehicule

Id	Type de véhicule	État (0 à 3)	Commandes
1	bicycle	3	91
2	electric_scooter	2	4 525
3	electric_scooter	3	239
4	motorcycle	0	18 726
5	motorcycle	1	9 473
6	motorcycle	2	4 733
7	motorcycle	3	112
8	scooter	1	9 291
9	scooter	2	9 597
10	scooter	3	205

dim_temps, dim_heure, dim_livreur, dim_conditions : extraits

`dim_temps` contient 55 jours consécutifs (11/02/2022 → 06/04/2022) ; `dim_heure` contient 24 heures et « Inconnue » ; `dim_livreur` 1 320 livreurs ; `dim_conditions` 72 combinaisons.

id_temps	date_complete	jour	nom_mois	nom_jour	semaine_iso	est_weekend
20220211	2022-02-11	11	février	vendredi	6	0
20220212	2022-02-12	12	février	samedi	6	1
20220213	2022-02-13	13	février	dimanche	6	1
20220214	2022-02-14	14	février	lundi	7	0
20220215	2022-02-15	15	février	mardi	7	0
20220216	2022-02-16	16	février	mercredi	7	0
20220217	2022-02-17	17	février	jeudi	7	0

id_livreur	code_livreur	ville
1	AGRRES010DEL01	Agra
2	AGRRES010DEL02	Agra
3	AGRRES010DEL03	Agra
4	AGRRES01DEL01	Agra
5	AGRRES01DEL02	Agra

id	meteo	trafic	festival
1	Cloudy	High	No
2	Cloudy	High	Yes
3	Cloudy	Jam	No
4	Cloudy	Jam	Yes
5	Cloudy	Low	Inconnu

Dimensions de l'enquête

Attribut de dim_profil_client	Valeurs (nombre de réponses)
Genre	Male : **222** · Female : **166**
Statut marital	Single : **268** · Married : **108** · Prefer not to say : **12**
Occupation	Student : **207** · Employee : **118** · Self Employed : **54** · House wife : **9**
Niveau d'études	Graduate : **177** · Post Graduate : **174** · Ph.D : **23** · School : **12** · Uneducated : **2**
Revenu mensuel (roupies)	No Income : **187** · 25001 to 50000 : **69** · More than 50000 : **62** · 10001 to 25000 : **45** · Below Rs.10000 : **25**
Type de client	Regular : **218** · Frequent : **146** · New : **24**

118 profils distincts et 77 codes postaux (de 560001 à 560109, secteur de Bangalore) pour 388 réponses.

5. Aperçu des tables de faits

Extraits lus dans la vue `vue_livraisons`, qui rassemble le fait et toutes ses dimensions. Les 56 992 lignes complètes sont dans la base et dans les fichiers CSV fournis ; un PDF ne peut pas les contenir toutes.

fait_livraisons : 10 premières commandes du jeu train

ID	Jeu	Date	Heure	Ville	Zone	Météo	Trafic	Véhicule	Dist. km	Prép. min	Livr. min
0x4607	train	2022-03-19	11h	Indore	Urban	Sunny	High	motorcycle	3,0	15	24
0xb379	train	2022-03-25	19h	Bangalore	Metropolitan	Stormy	Jam	scooter	20,2	5	33
0x5d6d	train	2022-03-19	08h	Bangalore	Urban	Sandstorms	Low	motorcycle	1,6	15	26
0x7a6a	train	2022-04-05	18h	Coimbatore	Metropolitan	Sunny	Medium	motorcycle	7,8	10	21
0x70a2	train	2022-03-26	13h	Chennai	Metropolitan	Cloudy	High	scooter	6,2	15	30
0x9bb4	train	2022-03-11	21h	Hyderabad	Urban	Cloudy	Jam	motorcycle	4,6	10	26
0x95b4	train	2022-03-04	19h	Ranchi	Metropolitan	Fog	Jam	scooter	16,6	15	40
0x9eb2	train	2022-03-14	17h	Mysore	Metropolitan	Cloudy	Medium	motorcycle	20,2	5	32
0x1102	train	2022-03-20	20h	Hyderabad	Metropolitan	Stormy	Jam	motorcycle	20,0	10	34
0xcdcd	train	2022-02-12	21h	Dehradun	Metropolitan	Fog	Jam	motorcycle	10,3	15	46

fait_livraisons : 3 commandes du jeu test (temps inconnu)

ID	Jeu	Date	Heure	Ville	Zone	Météo	Trafic	Véhicule	Dist. km	Prép. min	Livr. min
0x2318	test	2022-03-30	Inconnue	Coimbatore	Metropolitan	Inconnu	Inconnu	electric_scooter	6,2	—	—
0x3474	test	2022-03-29	20h	Bangalore	Metropolitan	Windy	Jam	motorcycle	17,1	5	—
0x9420	test	2022-03-10	19h	Jaipur	Metropolitan	Stormy	Jam	motorcycle	13,4	10	—

« — » signale une valeur vide (NULL) : ici le temps de livraison du jeu test, ou une distance non calculable lorsque les coordonnées du restaurant sont inutilisables.

fait_enquete : 10 premières réponses

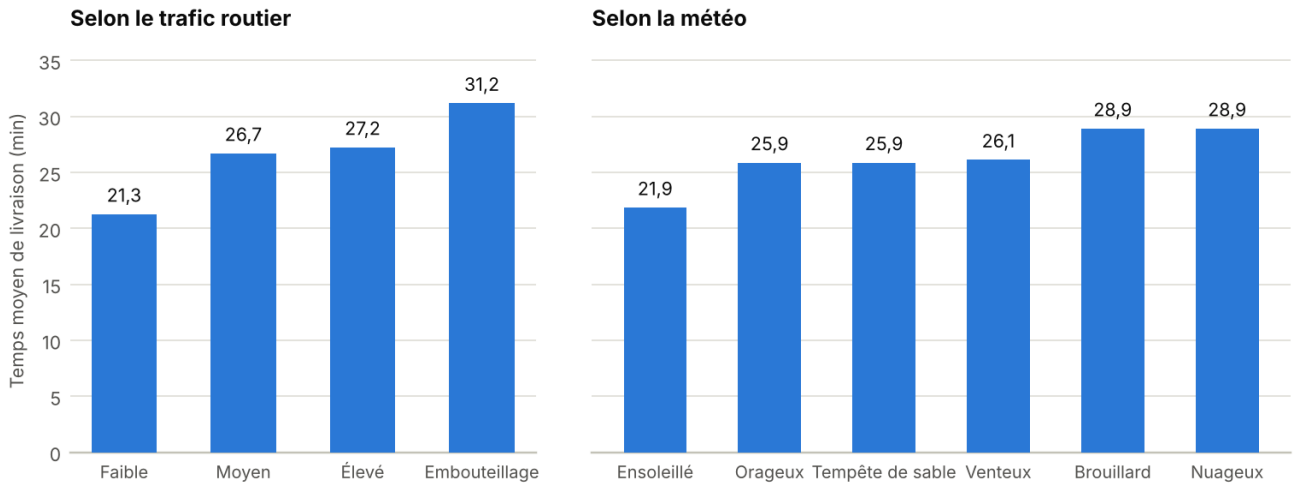
Id	Genre	Âge	Statut	Occupation	Études	Revenu	Client	Code post.	Foyer	Output	Avis +
1	Female	20	Single	Student	Post Graduate	No Income	Frequent	560001	4	1	1
2	Female	24	Single	Student	Graduate	Below Rs.10000	Regular	560009	3	1	1
3	Male	22	Single	Student	Post Graduate	Below Rs.10000	Regular	560017	3	1	0
4	Female	22	Single	Student	Graduate	No Income	Frequent	560019	6	1	1
5	Male	22	Single	Student	Post Graduate	Below Rs.10000	Frequent	560010	4	1	1
6	Female	27	Married	Employee	Post Graduate	More than 50000	Regular	560103	2	1	1
7	Male	22	Single	Student	Graduate	No Income	Regular	560009	3	1	1
8	Female	24	Single	Student	Post Graduate	No Income	Regular	560042	3	1	1
9	Female	23	Single	Student	Post Graduate	No Income	Regular	560001	2	1	1
10	Female	23	Single	Student	Post Graduate	No Income	Frequent	560048	4	1	1

6. Premières analyses

Ces résultats montrent ce que l'entrepôt permet de calculer. Ce sont des moyennes observées sur le jeu train (45 593 commandes avec temps de livraison), pas des effets isolés : les conditions se combinent dans les données.

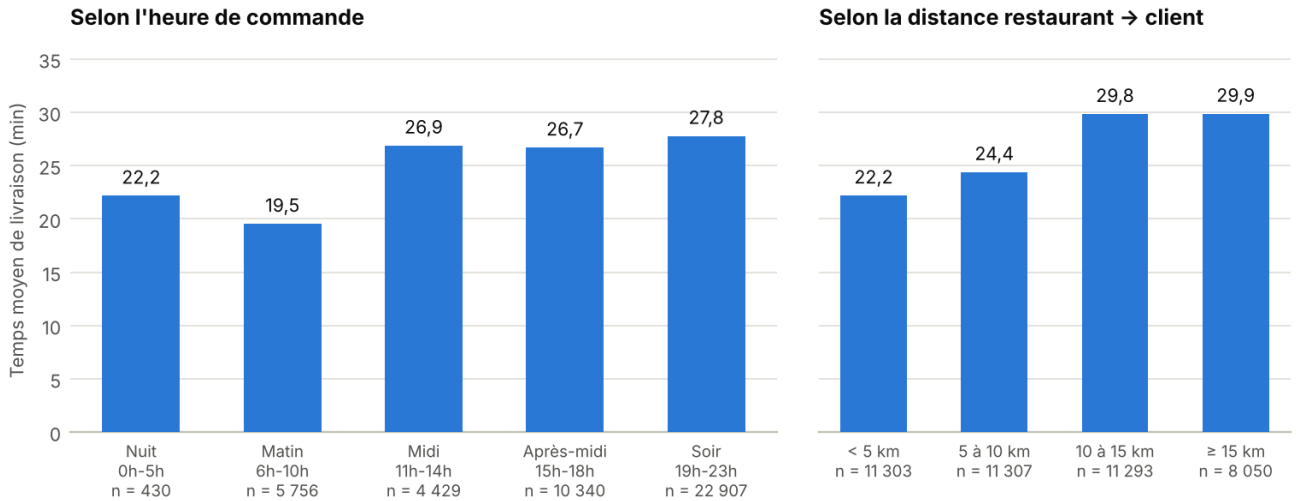
26,3 min	9,7 km	10,0 min	92,0 %
temps moyen de livraison	distance moyenne (coordonnées valides)	délai de préparation moyen	commandes à coordonnées exploitables

Temps de livraison selon le trafic et la météo



Le temps moyen passe de 21,3 min avec un trafic faible à 31,2 min en cas d'embouteillage. Il est de 21,9 min par temps ensoleillé et de 28,9 min par brouillard ou temps nuageux. Les valeurs « Inconnu » ne sont pas représentées.

Temps de livraison selon l'heure et la distance



Tranche la plus rapide : matin (19,5 min) ; tranche la plus chargée : soir (22 907 commandes). Le temps moyen augmente avec la distance, de 22,2 min sous 5 km à 29,9 min à partir de 15 km. Les distances ne sont calculées que pour les coordonnées valides.

Enquête : réponses « Output = Yes » et avis positifs

Critère	Groupe	Réponses	Output = Yes	Avis positifs
Type de client	Regular	218	78,9 %	82,1 %
	Frequent	146	76,7 %	82,2 %
	New	24	70,8 %	75,0 %
Occupation	Student	207	88,9 %	89,9 %
	Employee	118	64,4 %	72,0 %
	Self Employed	54	63,0 %	70,4 %
	House wife	9	77,8 %	88,9 %
Ensemble		**388**	**77,6 %**	**81,7 %**

Les étudiants (207 réponses) sont ceux qui répondent le plus souvent « Yes » à la question Output. Les groupes de moins de 25 réponses (clients nouveaux, femmes au foyer) sont trop petits pour conclure.

7. Qualité des données

Anomalies détectées dans les fichiers sources et traitement appliqué. Les données brutes restent intactes dans les tables de staging.

Anomalie	Lignes ou valeurs	Traitement
Espaces superflus en début/fin de valeur (toutes colonnes)	407 110	Supprimés
Valeurs manquantes écrites "NaN" (texte) au lieu de vide	11 512	Converties en NULL ; "Inconnu" dans les dimensions
Âge du livreur < 18 ans	47	Mis à NULL (valeur de la source conservée en staging)
Note du livreur > 5 (échelle 1 à 5)	63	Mise à NULL
Préfixe "conditions " devant la météo	56 992	Retiré (ex. "conditions Sunny" -> "Sunny")
Faute de frappe "Metropolitian"	42 590	Corrigée en "Metropolitan"
Heure de commande manquante	2 175	Heure = Inconnue (clé -1) ; délai de préparation NULL
Temps de livraison au format "(min) 24"	45 593	Converti en entier (24)
Commandes du jeu test sans temps de livraison	11 399	Temps = NULL (non inventé)
Coordonnées du restaurant négatives	545	Valeur absolue (l'écart restaurant-livraison devient cohérent, au plus 0,14 degré)
Coordonnées du restaurant à (0, 0) / hors Inde	4 510	Coordonnées et distance mises à NULL, coordonnees_valides = 0
Enquête : colonne "Unnamed: 13" identique à "Output"	388	Colonne supprimée
Enquête : espaces superflus	71	Supprimés
Enquête : lignes en double (aucun identifiant client)	103	Conservées (impossible de savoir si ce sont de vrais doublons)
Enquête : faute "Self Employeed"	54	Corrigée en "Self Employed"
Enquête : "Negative " avec espace final	71	Normalisé en Negative puis codé 0/1

Les coordonnées du restaurant à (0, 0) concernent 4 510 commandes sur 56 992 (7,9 %) : elles sont gardées dans l'entrepôt, mais sans coordonnées ni distance.

Contrôles de cohérence après chargement

Contrôle	Attendu	Obtenu	Statut
Lignes fait_livraisons = lignes train + test (staging)	56 992	56 992	**OK**
Commandes train chargées	45 593	45 593	**OK**
Commandes test chargées	11 399	11 399	**OK**
Identifiants de commande uniques	56 992	56 992	**OK**
Somme des temps de livraison : staging brut = fait	1 198 850	1 198 850	**OK**
Lignes fait_enquete = lignes enquête (staging)	388	388	**OK**
Réponses 'Output = Yes' : staging = fait	301	301	**OK**
Clés étrangères orphelines	0	0	**OK**
Commandes sans temps de livraison (hors jeu test)	0	0	**OK**
Distances négatives ou > 100 km	0	0	**OK**
Délais de préparation négatifs	0	0	**OK**
Commandes par ville : brut = fait	effectifs par ville (22)	identiques	**OK**

12 contrôles sur 12 réussis. Les comparaisons se font entre les tables de staging (données brutes) et les tables finales, avec un calcul indépendant.

8. Limites à connaître

- **Temps de livraison absent pour le jeu test.** Les 11 399 commandes du test n'ont pas de temps réel : la colonne est vide et les valeurs d'exemple de Sample_Submission.csv n'ont pas été utilisées.
- **L'enquête n'est pas reliée aux commandes.** Elle n'a pas d'identifiant client et concerne uniquement Bangalore : la seule jointure possible avec les livraisons est la ville.
- **Sens de la colonne Output non documenté** dans la source. Elle est conservée telle quelle sous le nom output_oui.
- **Noms de villes déduits** des préfixes des codes livreurs (ex. BANG pour Bangalore) ; la source ne les donne pas.
- **4 510 commandes sans coordonnées exploitables** (restaurant à 0, 0) : elles n'ont pas de distance.
- **Profil très uniforme** : 60 livreurs dans chaque ville et des temps moyens entre 26,0 et 27,0 min. Les comparaisons entre villes apportent peu d'information.
- **103 lignes de l'enquête sont en double.** Sans identifiant, impossible de savoir si ce sont de vrais doublons : elles sont conservées.
- **Âge et note du livreur varient pour un même livreur** d'une commande à l'autre dans la source, ce qui est inhabituel : ces valeurs sont à utiliser avec prudence.

Annexe : reproduire la construction

Le script `etl_entrepot.py` lit les trois fichiers sources, crée la base `entrepot_livraison.db` et le fichier `schema.sql`, puis exécute les contrôles. Il nécessite Python avec les bibliothèques pandas et numpy.

```
python3 etl_entrepot.py --train train.csv --test test.csv \
    --enquete "online food delivery dataset.csv" --out-dir sortie/
```

Exemples de requêtes d'analyse

```
-- Temps moyen de livraison selon le trafic
SELECT trafic, COUNT(*) AS commandes, ROUND(AVG(temps_livraison_min), 1) AS temps_moyen
FROM vue_livraisons
WHERE jeu_donnees = 'train'
GROUP BY trafic ORDER BY temps_moyen;

-- Commandes et temps moyen par ville
SELECT v.nom_ville, COUNT(*) AS commandes, ROUND(AVG(f.temps_livraison_min), 1) AS temps_moyen
FROM fait_livraisons f JOIN dim_ville v USING (id_ville)
GROUP BY v.nom_ville ORDER BY commandes DESC;

-- Enquête : part de réponses Output = Yes selon l'occupation
SELECT p.occupation, COUNT(*) AS reponses, ROUND(100.0 * AVG(e.output_oui), 1) AS pct_yes
FROM fait_enquete e JOIN dim_profil_client p USING (id_profil)
GROUP BY p.occupation;
```